RAPPORT DU PROJET IA

PREDICTION DU RISQUE D'ABANDON SCOLAIRE

Présenté par :

KOUASSI GUY CHARLES EMMANUEL

0714687062

Encadrant académique

Dr KAMAGATE BEMAN

Notre objectif est de créer un modèle de Machine Learning capable de prédire si un étudiant risque d'abandonner ses études, à partir de données académiques et comportementales.

1. Chargement de notre dataset

	age	gender	average_grade	absenteeism_rate	internet_access	study_time_hours	extra_activities	dropout_risk
0	21	Male	16.27	0.35	Yes	4.1	No	0
1	18	Female	12.30	0.38	No	0.2	No	1
2	22	Male	8.10	0.04	No	3.4	No	0
3	19	Male	13.84	0.25	No	4.8	Yes	0
4	21	Female	14.62	0.47	Yes	0.6	Yes	1

2. Observons la réparation du risque d'abandon (drpout_risk) qui represente la variable cible

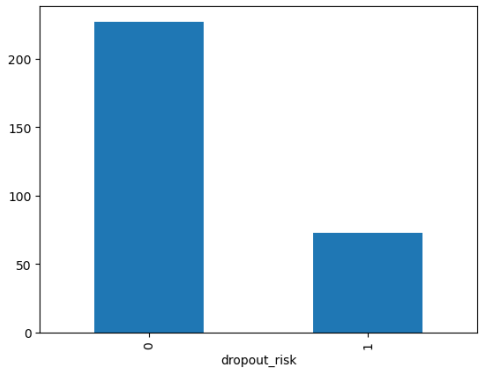

On constate ici qu'il y'a plus de succès que d'abandon scolaire au niveau de cette répartition

3. Analyse exploratoire des données

Observons la distribution des autres variables

*Absenteeisme_rate

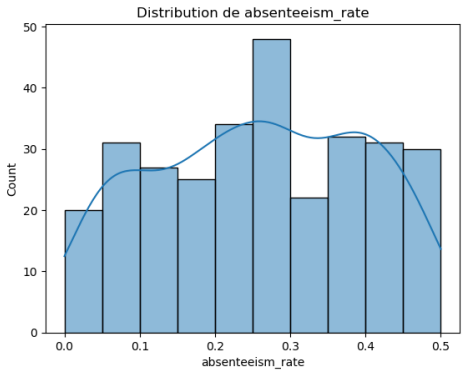

*Average_grade

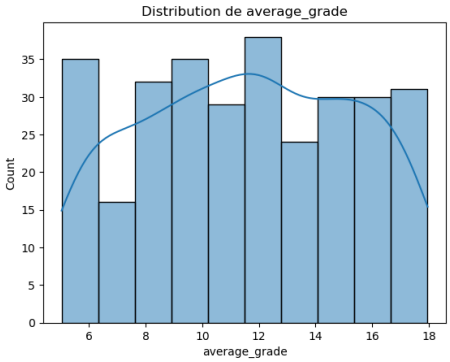

*Age

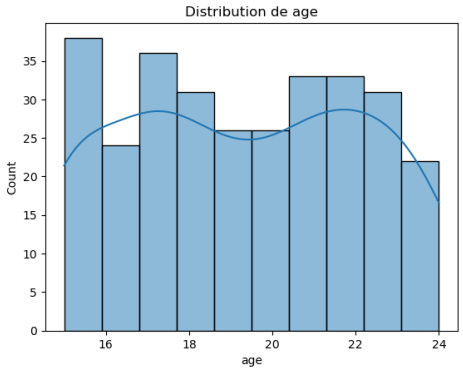

*Study_time_hours

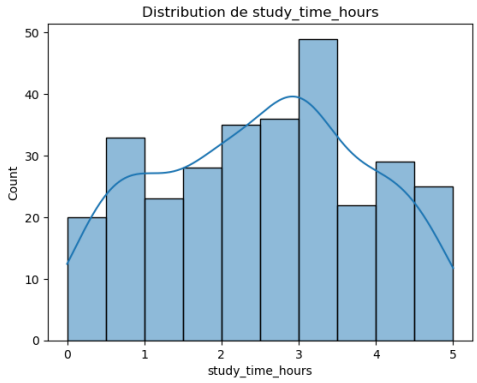

Matrice de corrélation de l'ensemble des variables

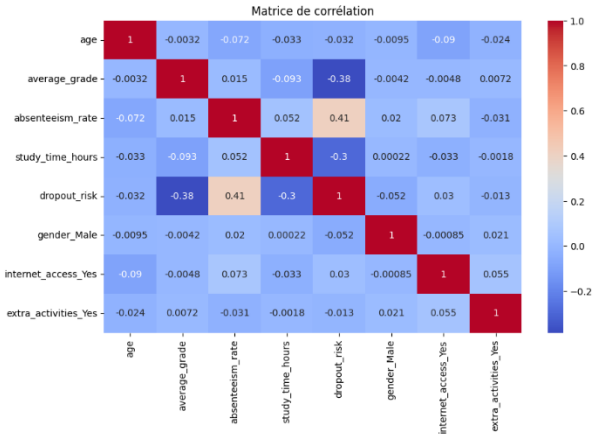

Identification des variables importantes

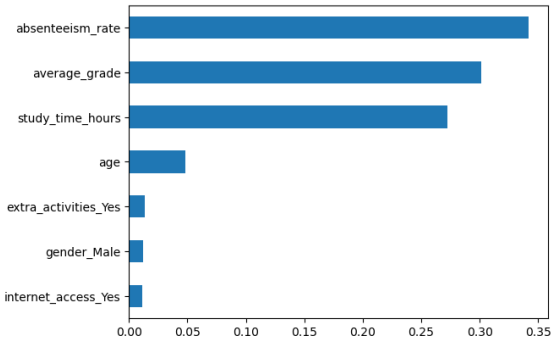

L'analyse a permis d'identifier que le taux d'absentéisme, la moyenne académique et le temps d'étude sont les variables les plus influentes dans la prédiction du risque d'abandon.

4. Création de nouvelles variables

Nous avons créé 2 nouvelles variables qui sont

taux_presence et global_score

nous avons essayé de voir la pertinence de ces variables afin de passer à l'implémentation de nos différents modèles.

```
corr = df.corr(numeric_only=True)['dropout_risk'].sort_values(ascending=False)
print(corr)
```

✓ 0.0s

```
dropout_risk            1.000000
absenteeism_rate        0.412653
internet_access_Yes     0.029846
extra_activities_Yes   -0.013273
age                    -0.032086
gender_Male            -0.051519
study_time_hours       -0.297416
average_grade          -0.384622
taux_presence          -0.412653
global_score           -0.454017
Name: dropout_risk, dtype: float64
```

Apres vérification de la pertinence des nouvelles variables nous avons retenus les variables suivantes pour l'implémentation de nos modèles

average_grade', 'absenteeism_rate', 'study_time_hours', 'global_score', 'taux_presence'

5. Implémentation des modèles (Régression logistique, Random forest, SVM)

	Model	Accuracy	Precision	Recall	F1-score
0	Logistic Regression	0.866667	0.777778	0.538462	0.636364
1	Random Forest	0.966667	0.923077	0.923077	0.923077
2	SVM	0.866667	0.727273	0.615385	0.666667

Voici les resultats obtenus à l'issus de l'implementation des differents modèles

Nous constatons que le modèle qui a performé sur toutes les metriques est le Random Forest.

C'est donc le meilleur modèle

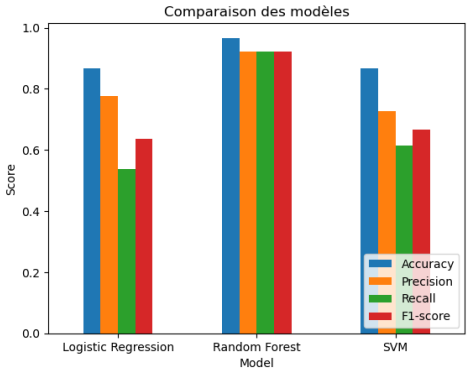

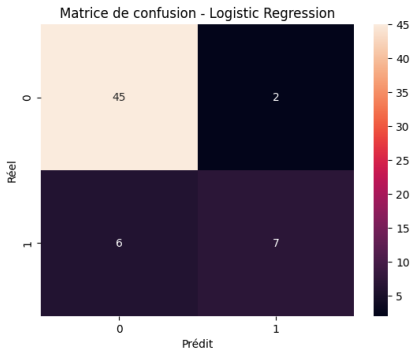

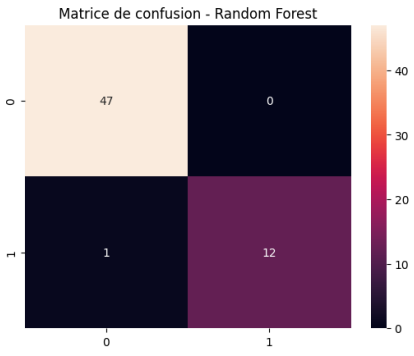

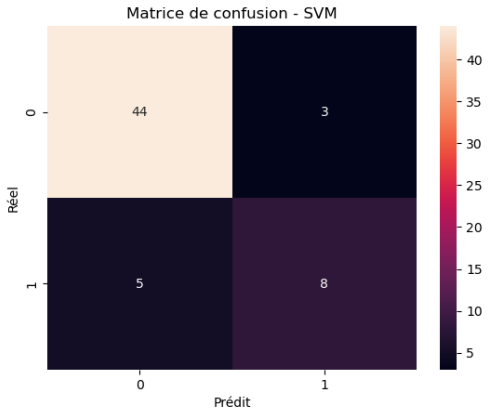

6. Demo de l'application

*Etape initial sans aucun choix

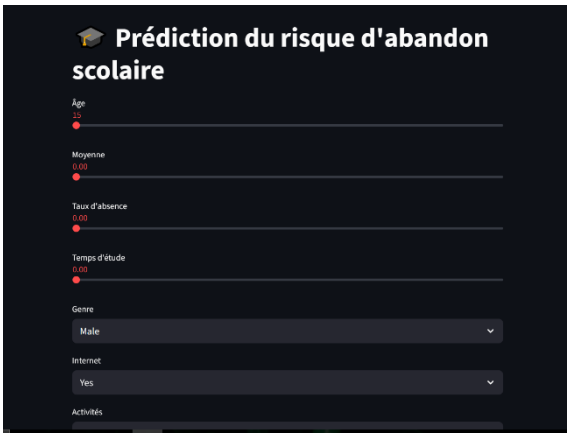

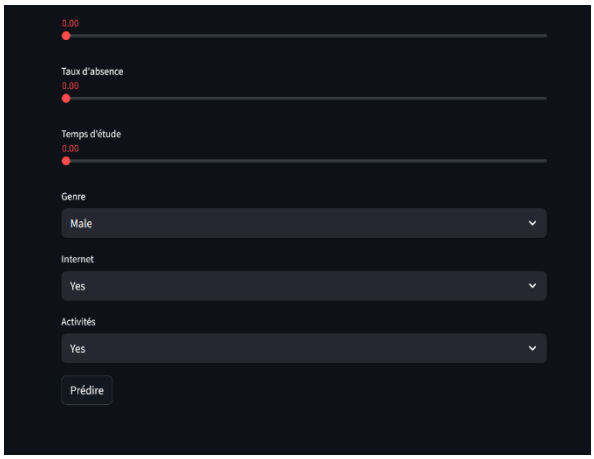

*Etape après avoir modifié la valeur des variables

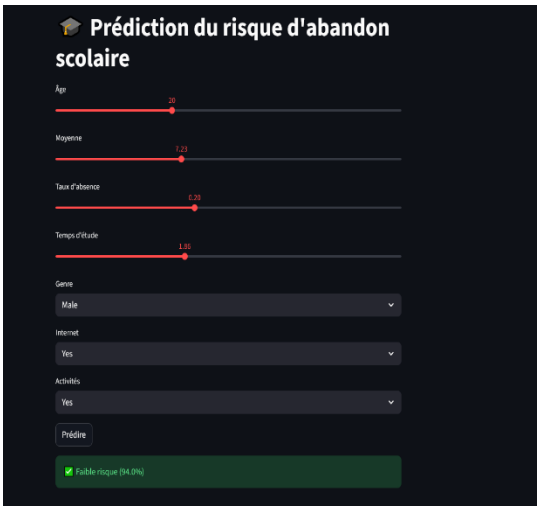
Prédiction du risque d'abandon scolaire
Âge
20
Moyenne
7.23
Taux d'absence
0.23
Temps d'étude
1.86
Genre
Male
Internet
Yes
Activités
Yes
Prédire
Faible risque (94.0%)

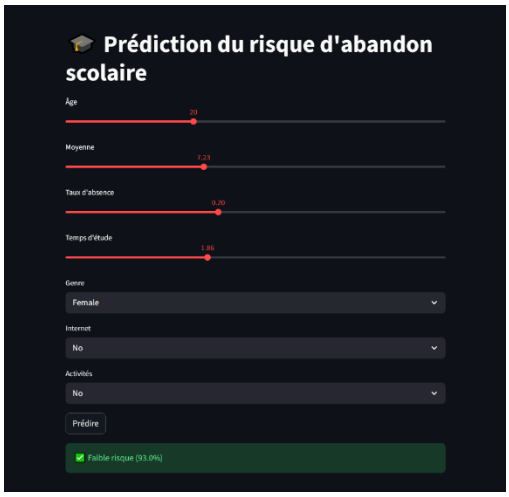
Prédiction du risque d'abandon scolaire
Âge
20
Moyenne
7.23
Taux d'absence
0.20
Temps d'étude
1.86
Genre
Female
Internet
No
Activités
No
Prédire
Faible risque (93.0%)

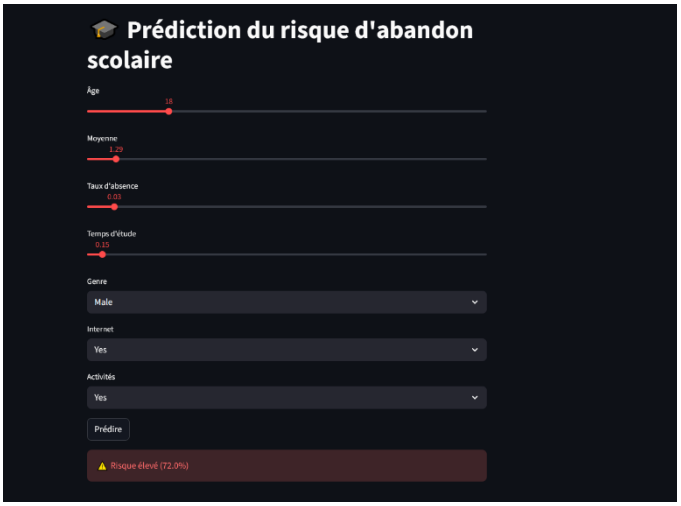
Prédiction du risque d'abandon scolaire
Âge
18
Moyenne
1.29
Taux d'absence
0.03
Temps d'étude
0.15
Genre
Male
Internet
Yes
Activités
Yes
Prédire
Risque élevé (72.0%)